

The background of the slide is a collage. At the top center is a grey square containing a stylized face with a dark circle for an eye and a white rectangle for a mouth. Below this, the background is split into two main sections. The left section shows a colorful, segmented map of a landscape with various shades of red, green, and blue. The right section shows a similar segmented image, but with a more pronounced, almost abstract, pattern of red and green. The text is overlaid on these sections.

Traitement des images

Segmentation de régions
et de contours

ENSEIRB Matméca / Bordeaux Sciences Agro
Christian GERMAIN Jean Pierre DA COSTA

PARTIE I

- GENERALITES, DEFINITIONS

1.1 Généralités: *Définitions*

- 1.1.1 Notion d'image numérique
- 1.1.2 Notion de causalité, de voisinage
- 1.1.3 Notion de stationnarité
- 1.1.4 Notion d'ergodicité

1.1 Généralités: *Définitions*

1.1.1 Notion d'image numérique

- Signal continu bidimensionnel:

$f(x,y)$ avec $(x,y) \in \mathbb{R}^2$ et $f(x,y) \in [0, \max]$.

- Echantillonnage de $f(x,y)$ selon $\Delta x \Delta y$ conduit à une série S : $s(i,j)=f(i.\Delta x, j.\Delta y)$ (i,j entiers). Attention à Shannon!
- Quantification de $S \Rightarrow$ image numérique
 $X : x_{ij} \in \Gamma = \{0, 1, \dots, \text{MAX}\}$; $i \in \{0, 1, \dots, N\}$ et $j \in \{0, 1, \dots, M\}$

1.1 Généralités: *Définitions*

1.1.1 Notion d'image numérique

Principales particularités des images vs un signal temporel (classique) :

- L'image est un signal bi-dimensionnel.
- La notion de temps n'a pas de sens, le passé et le futur sont remplacés par des notions de voisinage.
- L'information élémentaire : le pixel
Valeur : intensité lumineuse, couleur, autre...

1.1 Généralités: *Définitions*

1.1.2 Notion de causalité, de voisinage


- Signaux temporels => causaux
 - chaque échantillon a un passé et un futur.
Souvent les algo s'appuient sur le passé pour prédire l'avenir.
- Images :
 - temps remplacé par l'espace.
 - Pixel pas de passé et ni de futur.
 - Algo généralement non causaux.

1.1 Généralités: *Définitions*


1.1.2 Notion de causalité, de voisinage

- De la Causalité au Voisinage
 - L'algo exploite une zone entourant chaque pixel.
 - Le voisinage d'un pixel est l'ensemble des pixels qui sont ces voisins
 - Notion très large: n'importe quelle relation symétrique et anti-réflexive.

Exemples : le 4-Voisinage et le 8-Voisinage.



4-voisinage



8-voisinage

1.1 Généralités: *Définitions*


1.1.3 Notion de stationnarité

- signal stationnaire:
 - conserve ses propriétés statistiques après une translation quelconque de la zone considérée.
 - propriétés statistiques du signal à l'instant t et à l'instant $t+\Delta t$ doivent être identiques quel que soit Δt .
 - peut être limitée aux statistiques d'ordre 1, 2 ou plus.
- Image stationnaire:
 - propriétés statistiques conservées par translation
 - => identiques pour n'importe quelle sous-fenêtre de l'image.


1.1 Généralités: *Définitions*

1.1.3 Notion de stationnarité

- Image stationnaire



- Images non stationnaires






1.1 Généralités: *Définitions*

1.1.4 Notion d'ergodicité

- Un signal aléatoire est dit ergodique lorsque les statistiques temporelles du signal sont égales à ses statistiques d'ensemble.
- L'ergodicité d'un signal bidimensionnel (image) s'exprime en termes de moyenne spatiale versus moyenne d'ensemble.

1.2 Généralités: *Segmentation ou traitement des non stationnarités*



Approches “ contours ”

- Trouver les pixels de frontières




Approches “ régions ”

- Partitionner l'image en ensembles connexes de pixels R_i

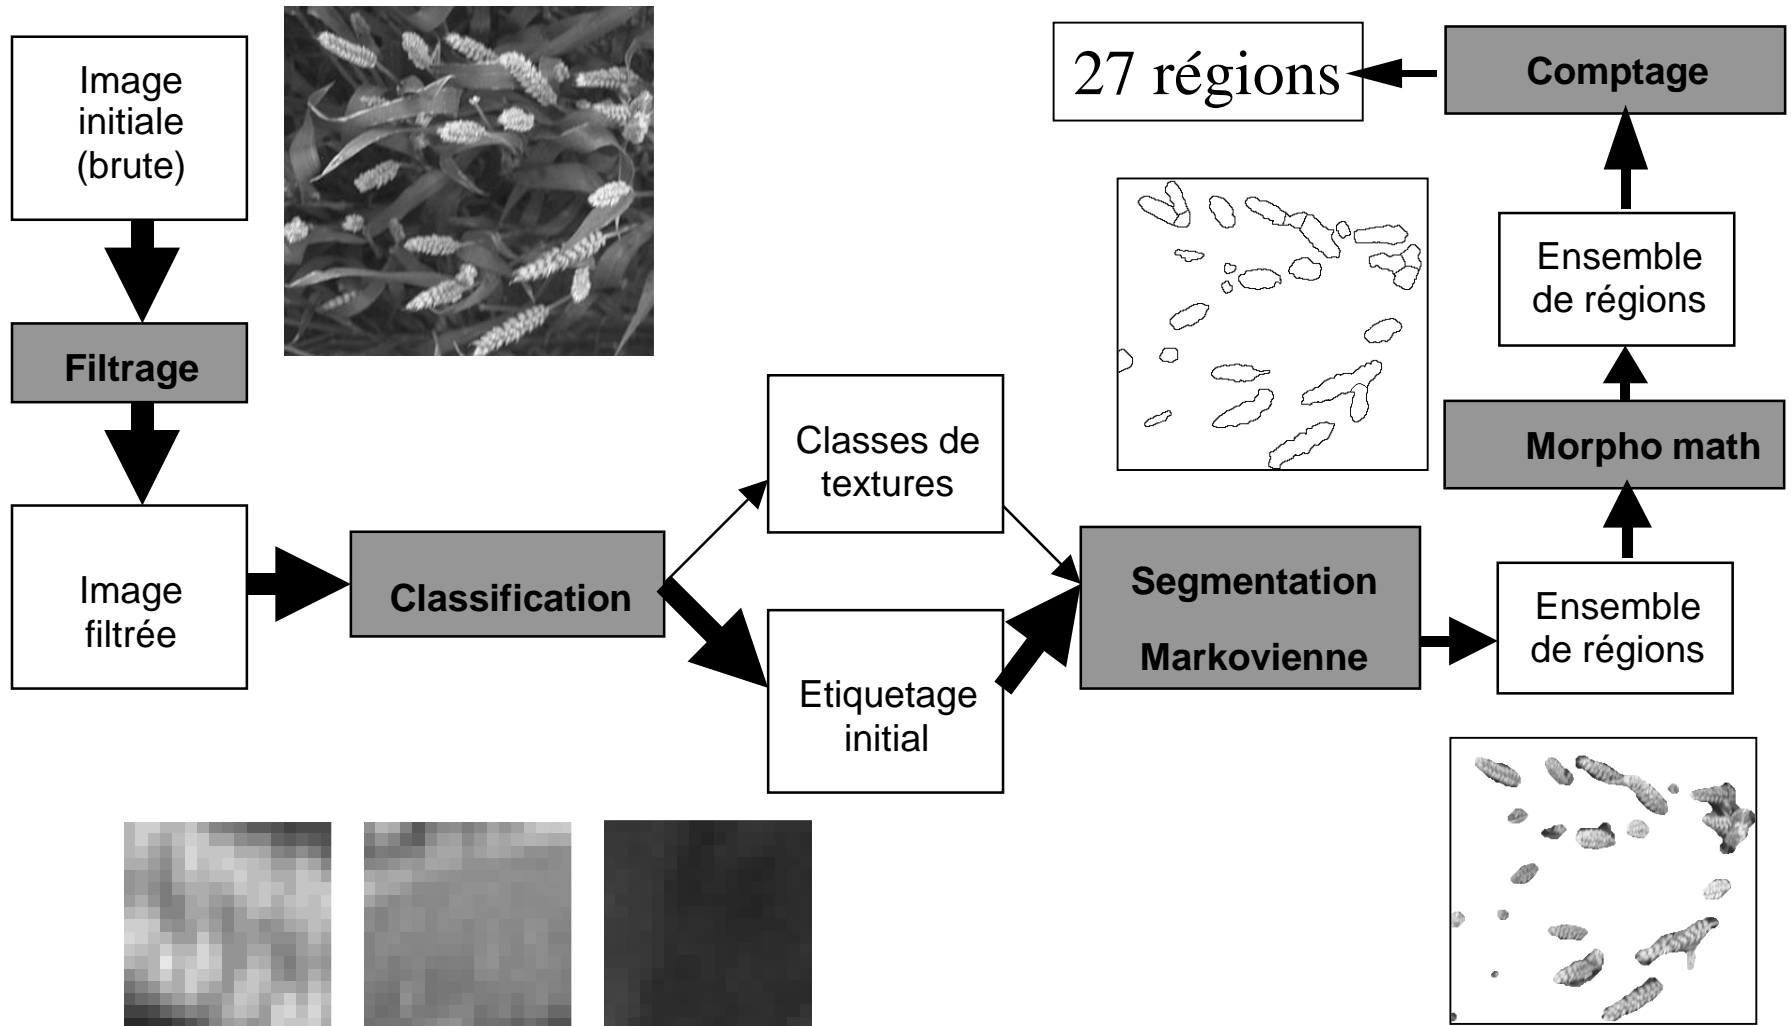
$$\bigcup_i R_i = X \quad \text{et} \quad R_i \cap R_j = \phi, \quad \forall i, j, \quad i \neq j$$

1.2 Généralités: *Segmentation ou traitement des non stationnarités*

Approches “ contours ” vs approches “ régions ”



1.3 GENERALITES: Segmentation dans la chaîne de traitement d'une image



PARTIE II

- SEGMENTATION DE REGIONS

Region Segmentation

Various Methods

- Threshold /Connected component labelling
- Statistics oriented (MRF)
- Computer oriented (Split & Merge)
- Practical (Region growing)
- Topological (Watershed, geodesic contours)



2.0 Segmentation de régions

Thresholding / Labelling



- Manual thresholding:
 - Mode, inter-mode
- Automatic thresholding:
 - Fisher, Entropic, ...
- Connected component labelling.
- Pros/Cons:
 - Simple and fast: if it works, do not hesitate!!!
 - But:
 - no region model, irregular shapes
 - class overlapping => labelling errors.
- Improvements: Adaptive thresholding.

2.0 Segmentation de régions



Limites du seuillage



2 pics+ peu de recouvrement:
Seuillage facile



3 pics + fort recouvrement:
Seuillage très difficile




1 seul pic:
Seuillage impossible

Images de matériaux fibreux

2.0 Segmentation de régions

Seuillage de Fisher

- Trouver la meilleure partition $P = \{C_1, C_2, \dots, C_N\}$



- Minimiser l'inertie de l'histogramme

$$W(P) = \sum_{i=1}^N \sum_{k \in C_i} h(k) \cdot (k - G(C_i))^2$$

$$\text{avec } G(C_i) = \frac{\sum_{k \in C_i} k \cdot h(k)}{\sum_{k \in C_i} h(k)}$$

2.1 Segmentation par modèles Markoviens (Markov Random Fields)



Problem description:

Number of classes : 5


Class standard deviation of the
grey levels: 8

Class average of the grey
levels :

27 46 111 120 179

The image to be segmented

Markov Random Fields



Hidden Markov field

Markov Random Fields

N number of pixels. $S = \{s_1, s_2, \dots, s_N\}$ the site grid.

K number of possible labels (number of classes).

$L = \{1, 2, \dots, K\}$ the labels.

V a neighborhood system (4-connexity) .

- If s and t are neighbor sites $s \in V(t)$ et $t \in V(s)$

Clique : a set of sites which are mutually neighbors:

- $\{s_1, s_2, \dots, s_p\}$ are in a clique if $\forall i$ and $j, i \neq j, s_i \in V(s_j)$

$A = \{a_s, s \in S\}$ the known field (pixels) ;

- a_s the grey level of site s .

$\Lambda = \{\lambda_s, s \in S\}$ the hidden field (the segmentation):

- λ_s the label of site s .

Ω the set of all the possible labelling Λ .

- $\text{Card } \Omega = ? \quad K^N$

Markov Random Fields

Labeling likelihood.

We know A , we want Λ . The problem is to maximize $P(\Lambda|A)$

From Bayes :

$$P(\Lambda|A) = \frac{P(A|\Lambda).P(\Lambda)}{P(A)}$$

Since A is known, we can maximize $P(A|\Lambda).P(\Lambda)$

Markov Random Fields

- Calculation of $P(A|\Lambda).P(\Lambda)$
- Grey levels are independent. Therefore: $P(A|\Lambda) = \prod_{s \in S} P(a_s | \lambda_s)$
- The grey level in each class being Gaussian:

$$P(a_s | \lambda_s) = \frac{1}{\sigma_{\lambda_s} \sqrt{2\pi}} \exp\left(-\frac{(a_s - \mu_{\lambda_s})^2}{2\sigma_{\lambda_s}^2}\right)$$

μ_{λ_s} and σ_{λ_s} being the mean and standard deviation of the grey level of then class λ_s

Markov Random Fields

- Calculation of $P(A|\Lambda).P(\Lambda)$
- Labels are NOT independent. Therefore: $P(\Lambda) = \prod_{s \in S} P(\lambda_s | \lambda_{t, t \neq s})$
- But Λ is markovian. So: $P(\Lambda) = \prod_{s \in S} P(\lambda_s | \lambda_{V(s)})$

Markov Random Fields

- Besides, Hammersley-Clifford says that a Markov Random Field (under some easy restrictions) can be expressed as a Gibbs Field for which the probability is well known in Physics:

$$P(\Lambda) = \exp(-U(\Lambda)) = \exp\left(-\sum_{c \in C} W_c(\lambda_c)\right)$$

U is the energy of the labeling.

The lower the energy, the more likely the labeling.

W_c is the clique c potential .

C being the whole set of cliques in the field.

Autologistic potential :

s_1 et s_2 being sites of clique c .

If $\lambda_{s1} = \lambda_{s2}$ then $W_c = -\beta$ else $W_c = +\beta$.

β parameter expresses the expected regularity of the labeling.

Markov Random Fields

We will minimize a pseudo energy E as:

$$E(A, \Lambda) = -\log(P(A|\Lambda).P(\Lambda))$$

Combining the previous relations we have:

$$E(A, \Lambda) = \sum_{s \in S} \left(\log(\sigma_{\lambda_s} \sqrt{2\pi}) + \frac{(a_s - \mu_{\lambda_s})^2}{2\sigma_{\lambda_s}^2} \right) + \sum_{c \in C} W_c(\lambda_c)$$

And locally:

$$e_s = \log(\sigma_{\lambda_s} \sqrt{2\pi}) + \frac{(a_s - \mu_{\lambda_s})^2}{2\sigma_{\lambda_s}^2} + \sum_{Cs} W_{Cs}(\lambda_{Cs})$$

Minimization: I.C.M.

(Iterated Conditional Mode)

- Deterministic method. Fast (several loop) but stops to the 1st local minimum of E.

Begin

Starting from a “good” initial labeling

Repeat

For each site s

Set the label which minimize the local energy e to s

End

Until convergence

End

- This algorithm is effective only when the initial labeling is close to the global minimum of E

Minimization: Metropolis

Begin
Starting from random initial labeling and choose temperature T
Repeat
 For each site \mathbf{s}
 Draw a candidate label \mathbf{x} and compute the local energy $e(\mathbf{s})$ & $e(\mathbf{x})$
 If $\mathbf{e}(\mathbf{x}) < \mathbf{e}(\mathbf{s})$ Then Set \mathbf{x} to \mathbf{s}
 Else Set \mathbf{x} to \mathbf{s} with a probability = $\mathbf{exp}(-\Delta\mathbf{e}/T)$
 End
End

Until convergence
End

- Algorithm optimal in theory... but unreasonably long !

Minimization:

Simulated annealing

Begin

Starting from random initial labeling and choose initial temperature T

Repeat

For each site \mathbf{s}

Draw a candidate label \mathbf{x} and compute the local energy $e(\mathbf{s})$ & $e(\mathbf{x})$

If $\mathbf{e}(\mathbf{x}) < \mathbf{e}(\mathbf{s})$ Then Set \mathbf{x} to \mathbf{s}

Else Set \mathbf{x} to \mathbf{s} with a probability = $\exp(-\Delta\mathbf{e}/T)$

End

End

Decrease T (i.e $T \leftarrow k * T$ with $k \in [0.8, 0.999]$)


Until convergence

End


- Algorithm usually suboptimal. Takes hundreds of iterations ($k > 0.9$)

2.1 Segmentation par *Modèles markoviens*

Exemple de résultat pour une relaxation markovienne




L'image à segmenter



Résultat

2.2 Segmentation par *Ligne de partage des eaux (Watershed)*


- 2.2.1 Principe
 - Une Image en niveaux de gris peut être considérée comme une surface topographique (un terrain pentu...)



2.2 Segmentation par *Ligne de partage des eaux (Watershed)*


- 2.2.1 Principe

- Remplir de la surface à partir ses minima ET empêcher l'eau en provenance de différentes sources de se mélanger
- Résultat:
 - Des bassins versants
 - et des lignes de partage des eaux




Segmentation par la ligne de partage des eaux

Analogie topographique




Segmentation par la ligne de partage des eaux

Simulation d'immersion




Segmentation par la ligne de partage des eaux


Simulation d'immersion



Première LPE



Deuxième LPE



Résultat

Segmentation par la ligne de partage des eaux

Simulation d'immersion

Début

Classer les sites par niveau de gris croissant.

Pour (tout h entre h_{min} et h_{max}) **faire**

Marquer tous les sites de niveau h avec le label M

Mettre en attente les sites ayant des voisins déjà labellisés ($\neq M$)

Tant que (file d'attente non vide) **faire**

Défiler un site s

Examiner son voisinage V_s

Si, sur V_s , on ne trouve qu'un seul label L ,

alors s reçoit ce label.

Si, sur V_s , il existe des labels différents,

alors s reçoit le label LPE

Si $\exists t \in V_s$ tel que t a le label M ,

alors mettre t en attente.

Fin Tant que

On repère tous les sites marqués (label M) mais non encore traités,
et on leur affecte des nouveaux labels.

Fin Pour

Fin

						L ₁	L ₁		
						L ₁	L ₁		
						L ₂			
						L ₂			
			L ₃	L ₃					

Fin de l'étape *h-1*


Tous les pixels de niveau inférieur à *h* ont été traités.
3 régions ont été identifiées.

						L ₁	L ₁		
						L ₁	L ₁		
		M			M	M			
						L ₂			
						L ₂			
			L ₃	L ₃					
			M					M	
								M	

Etape h

On marque tous les pixels de niveau h :






Etape h (suite)

On met en file d'attente ceux ayant des voisins labellisés






Etape h (suite...)

Pour chaque site s en attente, on examine ses voisins...

Si s n'est adjacent qu'à des sites de même label :
on lui affecte ce label.



Etape h (suite)

Si s est adjacent à 2 (ou plus) labels différents :
on le marque comme LPE.

Si un voisin de s a le label masque **M**, on met ce pixel en attente...

						L ₁	L ₁		
						L ₁	L ₁		
		M				LPE	LPE		
						L ₂			
						L ₂			
			L ₃	L ₃					
			L ₃					M	
								M	

Etape h (suite)

... et on le traite.

						L ₁	L ₁		
						L ₁	L ₁		
		L ₄				LPE	LPE		
						L ₂			
						L ₂			
			L ₃	L ₃					
			L ₃					L ₅	
								L ₅	

Etape h (fin)

On repère tous les sites marqués mais non encore traités :
on leur donne un nouveau label.

						L ₁	L ₁	M	
					M	L ₁	L ₁		
	M	L ₄			LPE	LPE			
						L ₂			
						L ₂			
			L ₃	L ₃					
			L ₃				M	L ₅	
								L ₅	

Etape h+1

On recommence...